

30 | 如何在系统中实现延迟监控？

2021-10-19 蒋德钧

《Redis源码剖析与实战》

课程介绍 >



讲述：蒋德钧

时长 14:58 大小 13.71M



你好，我是蒋德钧。

我们知道，Redis 的一个显著特征就是**能提供低延迟的数据访问**。而如果 Redis 在运行过程中变慢了，我们就需要有方法能监控到哪些命令执行变慢了。更进一步的需求，就是我们需要有方法监控到，是 Redis 运行过程中的哪些事件导致 Redis 变慢了。这样一来，我们就既可以检查这些慢命令，分析它们的操作类型和访问的数据量，进而提出应对方法，也可以检查监控记录的事件，分析事件发生的原因并提出应对方法。

那么，为了满足这些需求，我们就需要有一套监控框架，一方面能监测导致 Redis 变慢的事件，另一方面，能监控并记录变慢的命令。其实，这也是我们在开发后端系统时，经常会面临的一个运维开发需求，也就是**如何监控后端系统的运行状态**。

今天这节课，我就来带你了解 Redis 的延迟监控框架和慢命令日志的设计与实现。掌握今天的课程内容后，一方面，你可以把这套监控框架应用到实际的业务，而另一方面，你也可以参考

Redis 的实现，给自己的系统增加延迟监控功能。

下面，我们就先来看下 Redis 实现的延迟监控框架。

延迟监控框架的实现

实际上，Redis 在运行过程中，以下表格中给出的几类事件都会导致 Redis 变慢，我们通常也把这些事件称为**延迟事件**。你可以参考表格中的这些事件类型，以及它们在源码中对应的事件名称。

事件类型	源码中对应的具体事件名称
命令事件	command, fast-command
AOF事件	aof-write-pending-fsync, aof-write-active-child, aof-write-alone, aof-fstat, aof-rewrite-diff-write, aof-rename
fork事件	fork
过期key事件	expire-cycle
缓存替换事件	eviction-del, eviction-cycle



那么针对这些事件，Redis 实现了延迟监控框架，通过采样的方式来记录它们的执行情况。当需要排查问题时，延迟监控框架提供了 **latency history 命令**，以便运维人员检查这些事件。

下面，我们就来看下记录事件执行情况的数据结构。因为延迟监控框架是在 [latency.h](#)和 [latency.c](#)文件中实现的，你也可以在这两个文件中找到相应的数据结构和函数。

记录事件执行情况的数据结构


首先，Redis 是使用了 **latencySample 结构体**，来记录延迟事件的采样时间和事件的实际执行时长，这个结构体的代码如下所示：

复制代码

```
1 struct latencySample {
2     int32_t time; //事件的采样时间
```

```
3     uint32_t latency; //事件的执行时长（以毫秒为单位）
4 }
```

而在 latencySample 这个结构体基础上，Redis 又设计了 **latencyTimeSeries 结构体**，这个结构体使用了一个 latencySample 类型的数组，记录了针对某一类事件的一系列采样结果，这样就可以为分析 Redis 变慢提供更多的事件信息。

 复制代码


```
1 struct latencyTimeSeries {
2     int idx; //采样事件数组的写入位置
3     uint32_t max; //当前事件的最大延迟
4     struct latencySample samples[LATENCY_TS_LEN]; //采样事件数组，记录LATENCY_TS_LEN
5 };
```

另外，也因为延迟监控框架要记录的延迟事件有很多种，所以 Redis 还进一步设计了一个**哈希表 latency_events**，作为全局变量 server 的一个成员变量，用来记录不同事件的采样结果数组，如下所示：

 复制代码

```
1 struct redisServer {
2     ...
3     dict *latency_events;
4     ...
5 }
```

这个哈希表是在 Redis server 启动初始化的函数 initServer 中，通过调用 latencyMonitorInit 函数来完成创建的，如下所示：

 复制代码

```
1 void initServer(void) {
2     ...
3     latencyMonitorInit();
4 }
5
6 void latencyMonitorInit(void) {
7     server.latency_events = dictCreate(&latencyTimeSeriesDictType, NULL);
8 }
```

好，了解了记录延迟事件的数据结构和初始化操作后，我们再来看下事件采样是如何实现的。

如何实现延迟事件的采样？

延迟事件的**采样函数是 latencyAddSample**，它的函数原型如下所示。它的参数中包含了要记录的事件名称，这实际是对应了 latency_events 哈希表中的一个哈希项。此外，它的参数中还包括该事件的执行时长。

 复制代码

```
1 void latencyAddSample(char *event, mstime_t latency)
```

latencyAddSample 函数的执行逻辑并不复杂，主要可以分成三步。

首先，它会根据传入的事件名称，在 latency_events 哈希表中查找该事件。如果该事件对应的哈希项还不存在，它就会在哈希表中加入该事件，如下所示：

 复制代码

```
1 //查找事件对应的哈希项
2 struct latencyTimeSeries *ts = dictFetchValue(server.latency_events,event);
3 ...
4 if (ts == NULL) { //如果哈希项为空，就新建哈希项
5     ts = zmalloc(sizeof(*ts));
6     ts->idx = 0;
7     ts->max = 0;
8     memset(ts->samples,0,sizeof(ts->samples));
9     dictAdd(server.latency_events,zstrdup(event),ts); //在哈希表中插入哈希项
10 }
```

然后，latencyAddSample 函数会根据传入的事件执行时间，更新当前记录的该类事件的最大执行时间，如下所示：

 复制代码

```
1 if (latency > ts->max) ts->max = latency;
```

最后，latencyAddSample 函数会实际记录当前的采样结果。

不过在这一步，如果它发现当前的采样结果，和前一个采样结果是在同一秒中获得的，并且如果当前采样结果的事件执行时长，大于前一个采样结果的话，那么 `latencyAddSample` 函数就会直接更新前一个采样结果中记录的执行时长了，而不是新插入一个采样结果。

否则的话，`latencyAddSample` 函数才会新插入一个采样结果。这样设计的目的，也是为了避免在同一秒中记录过多的采样结果。

下面的代码展示了 `latencyAddSample` 函数实际记录采样结果的逻辑，你可以看下。

 复制代码

```
1 //获得同类事件的前一个采样结果
2 prev = (ts->idx + LATENCY_TS_LEN - 1) % LATENCY_TS_LEN;
3 if (ts->samples[prev].time == now) { //如果当前和前一个采样结果在同一秒中
4     if (latency > ts->samples[prev].latency) //如果当前采用结果的执行时长大于前一个
5         ts->samples[prev].latency = latency; //直接更新前一个采样结果的执行时长
6     return;
7 }
8 //否则，新插入当前的采样结果
9 ts->samples[ts->idx].time = time(NULL);
10 ts->samples[ts->idx].latency = latency;
```

而在这里，你也要注意一点，就是 `latencyAddSample` 函数在记录采样结果时，**会重复使用采样结果数组 `latencyTimeSeries`**。所以，如果采样结果数量超过数组默认大小时，旧的采样结果是会被覆盖掉的。如果你要记录更多的采样结果，就需要扩大 `latencyTimeSeries` 数组的长度。

那么，`latencyAddSample` 函数是在什么时候调用进行采样的呢？


其实，`latencyAddSample` 函数是被封装在了 **`latencyAddSampleIfNeeded` 函数**中。在 `latencyAddSampleIfNeeded` 函数中，它只会在事件执行时长超过 `latency-monitor-threshold` 配置项的值时，才调用 `latencyAddSample` 函数记录采样结果。你可以看看下面给出的 `latencyAddSampleIfNeeded` 函数定义。

 复制代码

```
1 #define latencyAddSampleIfNeeded(event,var) \
2     if (server.latency_monitor_threshold && \
3         (var) >= server.latency_monitor_threshold) \
4         latencyAddSample((event),(var));
```


而 `latencyAddSampleIfNeeded` 函数，实际上会在刚才介绍的延迟事件发生时被调用。这里我来给你举两个例子。

比如，当 Redis 命令通过 `call` 函数（在 `server.c` 文件中）执行时，`call` 函数就会调用 `latencyAddSampleIfNeeded` 函数进行采样，如下所示：

 复制代码

```
1 if (flags & CMD_CALL_SLOWLOG && c->cmd->proc != execCommand) {
2     //根据命令数据结构中flags的CMD_FAST标记，决定当前是fast-command事件还是command事件
3     char *latency_event = (c->cmd->flags & CMD_FAST) ?
4         "fast-command" : "command";
5     latencyAddSampleIfNeeded(latency_event,duration/1000);
6     ...
7 }
```

再比如，当 Redis 调用 `flushAppendOnlyFile` 函数写 AOF 文件时，如果 AOF 文件刷盘的配置项是 `AOF_FSYNC_ALWAYS`，那么 `flushAppendOnlyFile` 函数就会调用 `latencyAddSampleIfNeeded` 函数，记录 `aof-fsync-always` 延迟事件的采样结果，如下所示：

 复制代码

```
1 void flushAppendOnlyFile(int force) {
2     ...
3     if (server.aof_fsync == AOF_FSYNC_ALWAYS) {
4         latencyStartMonitor(latency); //调用latencyStartMonitor函数开始计时
5         redis_fsync(server.aof_fd); //实际将数据写入磁盘
6         latencyEndMonitor(latency); //调用latencyEndMonitor结束计时，并计算时长
7         latencyAddSampleIfNeeded("aof-fsync-always",latency);
8     ...}
9 }
```

那么在这里，你需要注意的是，Redis 源码在调用 `latencyAddSampleIfNeeded` 函数记录采样结果时，经常会在延迟事件执行前，调用 **`latencyStartMonitor` 函数**开始计时，并在事件执行结束后，调用 **`latencyEndMonitor` 函数**结束计时和计算事件执行时长。

此外，你也可以在阅读 Redis 源码的工具中，比如 `sublime`、`sourceinsight` 等，通过查找函数关系调用，找到 `latencyAddSampleIfNeeded` 函数被调用的其他地方。

好了，到这里，Redis 延迟监控框架就能通过 `latencyAddSampleIfNeeded` 函数，来记录延迟事件的采样结果了。而实际上，Redis 延迟监控框架还实现了延迟分析，并能提供应对延迟变慢的建议，我们再来看下。

延迟分析和提供应对措施建议

首先，Redis 是提供了 `latency doctor` 命令，来给出延迟分析结果和应对方法建议的。当我们执行这条命令的时候，Redis 就会使用 `latencyCommand` 函数来处理。而在处理这个命令时，`latencyCommand` 函数会调用 **`createLatencyReport` 函数**，来生成延迟分析报告和应对方法建议。

具体来说，`createLatencyReport` 函数会针对 `latency_events` 哈希表中记录的每一类事件，先调用 `analyzeLatencyForEvent` 函数，计算获得采样的延迟事件执行时长的均值、最大 / 最小值等统计结果。具体的统计计算过程，你可以仔细阅读下 `analyzeLatencyForEvent` 函数的源码。

然后，`createLatencyReport` 函数会针对这类事件，结合 Redis 配置项等信息给出应对措施。

其实，在 `createLatencyReport` 函数中，**它定义了多个 `int` 变量，当这些变量的值为 1 时，就表示建议 Redis 使用者采用一种应对高延迟的措施**。我在下面的代码中展示了部分应对措施对应的变量，你可以看下。另外你也可以阅读 `createLatencyReport` 函数源码，去了解所有的措施。

 复制代码

```
1 sds createLatencyReport(void) {
2 ...
3 int advise_slowlog_enabled = 0; //建议启用slowlog
4 int advise_slowlog_tuning = 0; //建议重新配置slowlog阈值
5 int advise_slowlog_inspect = 0; //建议检查slowlog结果
6 int advise_disk_contention = 0; //建议减少磁盘竞争
7 ...
8 }
```

我们也来简单举个例子。比如说，针对 `command` 事件，`createLatencyReport` 函数就会根据 `slowlog` 的设置情况，给出启用 `slowlog`、调整 `slowlog` 阈值、检查 `slowlog` 日志结果和避免使用 `bigkey` 的应对建议。这部分代码如下所示：

```

1  if (!strcasecmp(event,"command")) {
2      //如果没有启用slowlog, 则建议启用slowlog
3      if (server.slowlog_log_slower_than < 0) {
4          advise_slowlog_enabled = 1;
5          advices++;
6      } //如果slowlog使用的命令时长阈值太大, 建议调整slowlog阈值
7      else if (server.slowlog_log_slower_than/1000 >
8              server.latency_monitor_threshold)
9          {
10         advise_slowlog_tuning = 1;
11         advices++;
12     }
13     advise_slowlog_inspect = 1; //建议检查slowlog结果
14     advise_large_objects = 1; //建议避免使用bigkey
15     advices += 2;
16 }

```

所以，像 createLatencyReport 函数这样在计算延迟统计结果的同时，也给出应对措施的设计就很不错，这也是从 Redis 开发者的角度给出的建议，它更具有针对性。

好了，到这里，我们就了解了延迟监控框架的实现。接下来，我们再来学习下 Redis 中慢命令日志的实现。

慢命令日志的实现

Redis 是使用了一个较为简单的方法来记录慢命令日志，也就是用一个列表，把执行时间超出慢命令日志执行时间阈值的命令记录下来。

在 Redis 全局变量 server 对应的数据结构 redisServer 中，有一个 list 类型的成员变量 **slowlog**，它就是用来记录慢命令日志的列表的，如下所示：

```

1  struct redisServer {
2      ...
3      list *slowlog;
4      ...}

```

而实现慢命令日志记录功能的代码是在 [slowlog.c](#) 文件中。这里的主要函数是 **slowlogPushEntryIfNeeded**，它的原型如下所示：


```
1 void slowlogPushEntryIfNeeded(client *c, robj **argv, int argc, long long duratio
```

从代码中你可以看到，这个函数的参数包含了当前执行命令及其参数 argv，以及当前命令的执行时长 duration。

这个函数的逻辑也不复杂，它会判断当前命令的执行时长 duration，是否大于 redis.conf 配置文件中的慢命令日志阈值 slowlog-log-slower-than。如果大于的话，它就会调用 slowlogCreateEntry 函数，为这条命令创建一条慢命令日志项，并调用 listAddNodeHeader 函数，把这条日志项加入到日志列表头，如下所示：

```
1 //当前命令的执行时长是否大于配置项
2 if (duration >= server.slowlog_log_slower_than)
3     listAddNodeHead(server.slowlog, slowlogCreateEntry(c,argv,argc,duration));
```

当然，如果日志列表中记录了太多日志项，它消耗的内存资源也会增加。所以 slowlogPushEntryIfNeeded 函数在添加日志项时，会判断整个日志列表的长度是否超过配置项 slowlog-max-len。一旦超过了，它就会把列表末尾的日志项删除，如下所示：

```
1 //如果日志列表超过阈值长度，就删除列表末尾的日志项
2 while (listLength(server.slowlog) > server.slowlog_max_len)
3     listDelNode(server.slowlog,listLast(server.slowlog));
```

现在，我们也就了解了记录慢命令日志项的主要函数，slowlogPushEntryIfNeeded 的基本逻辑了。然后我们再来看下，它在记录日志项时调用的 **slowlogCreateEntry 函数**。

这个函数是用来创建一个慢命令日志项。慢命令日志项的数据结构是 slowlogEntry，如下所示：

```
1 typedef struct slowlogEntry {
2     robj **argv;    //日志项对应的命令及参数
3     int argc;       //日志项对应的命令及参数个数
4     long long id;    //日志项的唯一ID
```

```

5     long long duration; //日志项对应命令的执行时长（以微秒为单位）
6     time_t time;        //日志项对应命令的执行时间戳
7     sds cname;          //日志项对应命令的发送客户端名称
8     sds peerid;         //日志项对应命令的发送客户端网络地址
9 } slowlogEntry;

```

从 slowLogEntry 的定义中，你可以看到，它会把慢命令及其参数，以及发送命令的客户端网络地址记录下来。**这样设计的好处是**，当我们分析慢命令日志时，就可以直接看到慢命令本身及其参数了，而且可以知道发送命令的客户端信息。而这些信息，就有利于我们排查慢命令的起因和来源。

比如说，如果我们发现日志中记录的命令参数非常多，那么它就可能是一条操作 bigkey 的命令。

当然，考虑到内存资源有限，slowlogCreateEntry 函数在创建慢命令日志项时，也会判断命令参数个数。如果命令参数个数，超出了阈值 SLOWLOG_ENTRY_MAX_ARGC 这个宏定义的大小（默认 32）时，它就不会记录超出阈值的参数了，而是记录下剩余的参数个数。这样一来，慢命令日志项中就既记录了部分命令参数，有助于排查问题，也避免了记录过多参数，占用过多内存。

下面的代码展示了 slowlogCreateEntry 的基本执行逻辑，你可以看下。


 复制代码

```

1 slowlogEntry *slowlogCreateEntry(client *c, robj **argv, int argc, long long dura
2 slowlogEntry *se = zmalloc(sizeof(*se)); //分配日志项空间
3 int j, slargc = argc; //待记录的参数个数，默认为当前命令的参数个数
4
5 //如果当前命令参数个数超出阈值，则只记录阈值个数的参数
6 if (slargc > SLOWLOG_ENTRY_MAX_ARGC) slargc = SLOWLOG_ENTRY_MAX_ARGC;
7 se->argc = slargc;
8 ...
9 for (j = 0; j < slargc; j++) { //逐一记录命令及参数
10     if (slargc != argc && j == slargc-1) { //如果命令参数个数超出阈值，使用最后一个参数i
11         se->argv[j] = createObject(OBJ_STRING,
12             sdscatprintf(sdsempty(), "... (%d more arguments)",
13                 argc-slargc+1));
14     } else {
15         ... //将命令参数填充到日志项中
16     }
17 ... //将命令执行时长、客户端地址等信息填充到日志项中
18 }

```

好了，到这里，你就了解了慢命令日志的实现。最后，你也要注意，**慢命令日志只会记录超出执行时长阈值的命令信息**，而不会像延迟监控框架那样记录多种事件。所以，记录日志的函数 `slowlogPushEntryIfNeeded`，只会在命令执行函数 `call`（在 `server.c` 文件中）中被调用，如下所示：

 复制代码

```
1 void call(client *c, int flags) {
2     ...
3     start = server.ustime; //命令执行前计时
4     c->cmd->proc(c); //命令实际执行
5     duration = ustime()-start; //命令执行完成计算耗时
6     ...
7     if (flags & CMD_CALL_SLOWLOG && c->cmd->proc != execCommand) {
8         ...
9         //调用slowlogPushEntryIfNeeded函数记录慢命令
10        slowlogPushEntryIfNeeded(c,c->argv,c->argc,duration);
11    }
12    ...}
```

小结

今天这节课，我给你介绍了 Redis 实现的延迟监控框架和慢命令日志。你要知道，Redis 源码会针对可能导致 Redis 运行变慢的五类事件，在它们执行时进行**采样**。而一旦这些事件的执行时长超过阈值时，监控框架就会将采样结果记录下来，以便后续分析使用。这种针对延迟事件进行采样记录的监控方法，其实是很值得我们学习的。

而慢命令日志的实现则较为简单，就是针对运行时长超出阈值的命令，使用一个**列表**把它们记录下来，这里面包括了命令及参数，以及发送命令的客户端信息，这样可以方便运维人员查看分析。

当然，Redis 源码中实现的延迟监控框架主要是关注导致延迟增加的事件，它记录的延迟事件，也是和 Redis 运行过程中可能会导致运行变慢的操作**紧耦合**的。此外，Redis 的 `INFO` 命令也提供了 Redis 运行时的监控信息，不过你要知道，`INFO` 命令的实现，主要是在全局变量 `server` 的成员变量中，用来记录 Redis 实例的实时运行状态或是资源使用情况的。

每课一问

Redis 在命令执行的 `call` 函数中，为什么不会针对 `EXEC` 命令，调用 `slowlogPushEntryIfNeeded` 函数记录慢命令呢？

分享给需要的人，Ta订阅超级会员，你最高得 50 元

Ta单独购买本课程，你将得 20 元

 生成海报并分享

 赞 2  提建议

© 版权归极客邦科技所有，未经许可不得传播售卖。页面已增加防盗追踪，如有侵权极客邦将依法追究其法律责任。

上一篇 29 | 如何正确实现循环缓冲区？

下一篇 31 | 从Module的实现学习动态扩展功能

限定福利

限定福利

给 Java 工程师 免费送 5 节课

0 元领课 

加赠 PPT

 资深大厂
专家亲授

 大厂会考
的面试题

100%

 能落地的
实战经验

 解决问题的
思路和方法

精选留言 (1)

 写留言



斩弦

2021-10-19

蒋老师好，今天很巧正好在思考延时的问题，同时看到了更新了这节课，
我的问题(1) ./redis-cli --intrinsic-latency xxx这个命令能够看到内核本身的延时，因为我们的redis环境是部署在虚拟化环境的，时不时会有延时增大的现象发生，也有过发生问题后排查到集中发生在某个虚机所在的宿主机上，问题处理就是将这个虚机迁移到了其他的宿主机上，那么能否围绕./redis-cli --intrinsic-latency这个命令，我们可以自行开发一个逻辑，每10s或者15s采样一次，然后作为CPU内核延时的指标值，放到我们的监控逻辑中，这个耗时可以作为问题出现时的一个参考，作为问题出现时的一个重要的延时的成分；
另外还有一个问题(2) latency monitor这个功能对系统的性能影响是否明显呢，其实看到了这个功能后，有想要尝试使用这个功能以扩展延时问题排查时的手段

